ANALISIS PERFORMA ARSITEKTUR PANNs DENGAN PENDEKATAN INPUT BERBASIS *RAW WAVEFORM*, *LOG-MEL SPECTROGRAM*, DAN *HYBRID* UNTUK KLASIFIKASI SUARA KEDARURATAN PERKOTAAN

TUGAS AKHIR

Diajukan sebagai syarat menyelesaikan jenjang strata Satu (S-1) di Program Studi Teknik Informatika, Fakultas Teknologi Industri, Institut Teknologi Sumatera

Oleh:

Ramon Riping

122140078

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN

2026

DAFTAR ISI

DAFTAR ISI . . . . . **ii**

DAFTAR TABEL . . . . . **iv**

DAFTAR GAMBAR . . . . . **v**

DAFTAR RUMUS . . . . . **vi**

BAB I PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 4

1.3 Tujuan Penelitian 5

1.4 Batasan Masalah 5

1.5 Manfaat Penelitian 5

1.6 Sistematika Penulisan 6

BAB II TINJAUAN PUSTAKA **8**

2.1 Tinjauan Pustaka 8

2.2 Dasar Teori 8

2.2.1 *Environmental Sound Classification* (ESC) 8

2.2.2 Konsep Suara Digital 9

2.2.3 Dataset UrbanSound8K 12

2.2.4 Prapemrosesan Data 13

2.2.5 Representasi Input Suara 16

2.2.5.1 *Raw Waveform* 17

2.2.5.2 *Log-mel Spectrogram* 17

2.2.6 Augmentasi Data 18

2.2.6.1 *Random Cropping* 19

2.2.7 *Convolutional Neural Network* (CNN) 19

2.2.7.1 *Kernel* dan *Stride* 20
2.2.7.2 *Batch Normalization* (BN) 20
2.2.7.3 *Rectified Linear Unit* (ReLU) 21
2.2.7.4 *Max Pooling* 22
2.2.7.5 *Fully Connected Layer* 22
2.2.7.6 *Sigmoid* 23
2.2.7.7 *Softmax* 23
2.2.8 *Pre-trained Audio Neural Networks* (PANNs) 24
2.2.8.1 Res1dNet31 25
2.2.8.2 ResNet38 26
2.2.8.3 Wavegram-Logmel-CNN14 27

BAB III METODE PENELITIAN 28
3.1 Alur Penelitian 28
3.2 Pengumpulan dan Prapemrosesan Data 31
3.2.1 Seleksi Kelas 31
3.2.2 Strategi Penyusunan Ulang Data (*Fold Mapping*) 32
3.2.3 Standarisasi Format Audio 33
3.2.4 Augmentasi Temporal (*Random Cropping*) 34
3.3 Konfigurasi Model 36
3.3.1 Modifikasi Arsitektur PANNs 36
3.3.2 Parameter Konfigurasi Input 37
3.4 Eksperimen *Transfer Learning* 37
3.4.1 Lingkungan Implementasi dan Reproduksibilitas 38
3.4.2 Penanganan Ketidakseimbangan Data (*Cost-Sensitive Learning*) 40
3.4.3 Konfigurasi *Optimizer* dan *Scheduler* 41
3.4.4 Strategi Optimasi: *Early Stopping* dan *Checkpoint* 42
3.4.5 Pemantauan dan Pencatatan Eksperimen 44

3.4.6 Konfigurasi Parameter Pelatihan 44
3.5 Analisis dan Evaluasi 45

DAFTAR PUSTAKA **47**

DAFTAR TABEL

Tabel 3.1 Konfigurasi Parameter Input Audio Model PANNs 37
Tabel 3.2 Spesifikasi Perangkat Keras untuk Pelatihan 39
Tabel 3.3 Daftar Perangkat Lunak dan Pustaka Pendukung 39
Tabel 3.4 Parameter Konfigurasi Pelatihan 45

DAFTAR GAMBAR

Gambar 3.1 Diagram Alur Penelitian 28
Gambar 3.2 Ilustrasi Strategi Penyusunan Ulang Fold pada Dataset UrbanSound8K 33
Gambar 3.3 Ilustrasi Teknik *Random Cropping* 35
Gambar 3.4 Ilustrasi Mekanisme *Checkpointing* 43

DAFTAR RUMUS

Rumus 2.1 Konversi *Stereo* ke *Mono* 14
Rumus 2.2 Operasi *Zero-Padding* 15
Rumus 2.3 Rumus Fungsi Aktivasi *Sigmoid* 23
Rumus 2.4 Rumus Fungsi Aktivasi *Softmax* 24
Rumus 3.1 *Cost Sensitive-Learning* 41

BAB I
PENDAHULUAN

1.1 Latar Belakang

Keselamatan berlalu lintas di lingkungan perkotaan merupakan tantangan krusial yang dihadapi masyarakat saat ini, terutama bagi kelompok rentan seperti penyandang disabilitas [1]. Dalam aktivitas tersebut, indra pendengaran berperan sebagai mekanisme deteksi alami yang penting untuk mengetahui kondisi lingkungan di sekitar. Namun, fungsi indra tersebut tidak dimiliki oleh penyandang tunarungu, yang hanya bisa mengandalkan penglihatan mereka untuk memantau keadaan. Ketergantungan penuh pada aspek visual ini dapat menjadi kerentanan serius, mengingat mereka memiliki keterbatasan sudut pandang dan tidak dapat memantau kondisi di luar jangkauan penglihatan. Akibatnya, ancaman yang muncul dari titik buta (*blind spot*), seperti gonggongan dari anjing yang mengejar atau klakson kendaraan yang melaju kencang dari arah belakang, seringkali terlambat disadari akibat tidak adanya peringatan suara. Keterlambatan respon inilah yang secara signifikan meningkatkan risiko terjadinya kecelakaan fatal [2]. Maka dari itu, diperlukan mekanisme bantu yang dapat menggantikan peran indra pendengaran dalam mendeteksi ancaman yang muncul dari luar jangkauan visual.

Saat ini, Alat Bantu Dengar (ABD) merupakan perangkat yang umum digunakan untuk menunjang komunikasi verbal penyandang tunarungu. Meskipun efektif untuk komunikasi verbal jarak dekat, alat ini memiliki keterbatasan signifikan dalam konteks keselamatan di luar ruangan. Hal ini disebabkan oleh penurunan selektivitas frekuensi (*reduced frequency selectivity*) yang umum terjadi pada gangguan pendengaran sensorineural, sehingga menyulitkan pemisahan sinyal suara utama dari kebisingan latar belakang yang tumpang tindih [3]. Kondisi ini diperburuk oleh keterbatasan

teknis ABD, di mana sekadar amplifikasi sinyal suara tidak cukup untuk mengembalikan kemampuan pemilahan suara secara alami. Akibatnya, sinyal ancaman penting seringkali tertutup oleh suara-suara lainnya, yang berdampak pada hilangnya kewaspadaan situasional pengguna. Keterbatasan perangkat keras dalam memilah sinyal suara ini memunculkan kebutuhan teknologi bagi penyandang tunarungu agar dapat mengidentifikasi suara bahaya melalui pola sinyal suara, dan bukan sekadar amplifikasi sinyal.

Guna mengatasi keterbatasan ini, dikembangkanlah metode cerdas yang dikenal sebagai Klasifikasi Suara Lingkungan atau *Environmental Sound Classification* (ESC). Integrasi teknologi ini pada alat bantu dengar telah lama diteliti sebagai upaya meningkatkan kesadaran situasi pengguna [4]. Pada tahap awal pengembangannya, sistem ESC umumnya dibangun menggunakan metode *Machine Learning* konvensional seperti *Support Vector Machine* (SVM) atau *Random Forest* [5]. Namun, metode-metode klasik tersebut sangat bergantung pada proses ekstraksi fitur secara manual (*hand-crafted features*) yang kaku, sehingga performanya cenderung menurun drastis ketika dihadapkan dengan variasi kebisingan lingkungan yang dinamis. Kelemahan metode tersebut memicu pergeseran tren penelitian menuju pendekatan *Deep Learning*, khususnya *Convolutional Neural Networks* (CNN) yang menawarkan kemampuan untuk mempelajari fitur suara secara otomatis dan hirarkis langsung dari data [6]. Kemampuan adaptasi fitur inilah yang menjadikannya sebagai solusi yang jauh lebih andal dibandingkan metode konvensional. Walaupun menjanjikan akurasi yang lebih tinggi, metode *Deep Learning* membutuhkan dataset berskala masif untuk melatih fitur-fitur tersebut secara efektif. Ketergantungan ini menjadi kendala signifikan pada kasus dengan ketersediaan data yang terbatas, sehingga diperlukan strategi pembelajaran khusus agar model tetap memiliki performa yang *robust*.

Sebagai implementasi strategi tersebut, metode *Transfer Learning* menjadi solusi efektif untuk mengatasi kelangkaan data. Pendekatan ini memanfaatkan

Pre-trained Audio Neural Networks (PANNs) [7], yaitu sebuah kerangka kerja model *Deep Learning* skala besar yang telah dilatih sebelumnya (*pre-trained*) pada dataset AudioSet [8] untuk mengenali berbagai pola suara umum. Salah satu keunggulan PANNs terletak pada variasi arsitektur yang dirancang khusus untuk menangani dua jenis representasi input audio yang berbeda. Pertama adalah arsitektur berbasis satu dimensi yang mengolah *Raw Waveform*, yaitu sinyal gelombang suara mentah dalam domain waktu. Kedua adalah arsitektur berbasis dua dimensi yang memanfaatkan *Log-mel Spectrogram*, yaitu representasi visual yang memetakan intensitas energi frekuensi suara layaknya sebuah citra gambar. Selain itu, PANNs juga menyediakan arsitektur dengan pendekatan *Hybrid* yang menggabungkan kedua representasi tersebut, yang secara teoritis berpotensi memaksimalkan akurasi deteksi. Ketersediaan variasi ini memunculkan urgensi untuk mengevaluasi arsitektur mana yang paling optimal untuk diterapkan pada kasus ini, apakah berbasis domain waktu, domain frekuensi, atau penggabungan keduanya (*Hybrid*).

Meskipun Kong et al. [7] telah memaparkan tolak ukur kinerja model-model tersebut pada dataset masif AudioSet [8], performa tersebut belum tentu sebanding ketika diterapkan pada kasus penerapan spesifik dengan ketersediaan data yang terbatas (*data scarcity*) seperti pada kasus klasifikasi suara lingkungan perkotaan. Perbedaan karakteristik data ini memunculkan dugaan bahwa kompleksitas arsitektur model *Hybrid* dan *Log-mel Spectrogram* justru memiliki risiko *overfitting* yang lebih tinggi dibandingkan model *Raw Waveform* ketika dilatih pada dataset yang kecil. Selain itu, terdapat juga perbedaan mendasar pada jenis keluaran klasifikasi, di mana PANNs dilatih untuk mendeteksi banyak label sekaligus (*Multi-Label*), sedangkan penelitian ini dirancang untuk memprioritaskan identifikasi sumber bahaya paling dominan (*Single-Label*). Pendekatan *Single-Label* ini dipilih untuk menyelaraskan karakteristik dataset UrbanSound8K yang memiliki anotasi satu sumber suara dominan (*salient event*), serta guna menghindari ambiguitas peringatan agar pengguna dapat

mengambil keputusan responsif. Ketidakpastian inilah yang menjadi celah penelitian (*research gap*) yang belum terjamah. Oleh karena itu, penelitian ini menjadi krusial untuk mengevaluasi ulang adaptabilitas dan melakukan analisis komparasi ketiga arsitektur tersebut secara spesifik pada dataset UrbanSound8K.

Guna menjawab tantangan adaptabilitas pada dataset terbatas tersebut, penelitian ini bertujuan utama secara teknis untuk menginvestigasi dan membandingkan kinerja tiga pendekatan representasi input, yaitu *Raw Waveform*, *Log-mel Spectrogram*, dan *Hybrid* dalam mengklasifikasikan suara tanda bahaya yang mengancam keselamatan penyandang tunarungu. Studi komparasi ini diposisikan sebagai langkah fundamental untuk menemukan konfigurasi model yang paling *robust* (tahan uji) terhadap minimnya data, sekaligus meminimalisir kesalahan deteksi fatal. Dengan demikian, hasil evaluasi ini diharapkan dapat menjadi landasan teknis yang valid bagi pengembangan teknologi asistif yang benar-benar andal untuk menjamin keselamatan komunitas tunarungu.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah:

1. Bagaimana pengaruh perbedaan representasi input (*Raw Waveform*, *Log-mel Spectrogram*, dan *Hybrid*) terhadap performa model *Pre-trained Audio Neural Networks* (PANNs) dalam mengklasifikasikan suara bahaya pada kondisi ketersediaan data yang terbatas?
2. Representasi input manakah yang menghasilkan model paling optimal berdasarkan metrik *F1-Score*, nilai *Loss*, dan analisis *Confusion Matrix* untuk meminimalisir kesalahan deteksi pada sistem keselamatan penyandang tunarungu?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah :

1. Menganalisis pengaruh perbedaan representasi input (*Raw Waveform*, *Log-mel Spectrogram*, dan *Hybrid*) terhadap performa model *Pre-trained Audio Neural Networks* (PANNs) dalam mengklasifikasikan suara bahaya pada kondisi ketersediaan data yang terbatas.
2. Mengevaluasi pendekatan representasi input yang menghasilkan model paling optimal berdasarkan metrik *F1-Score*, nilai *Loss*, dan analisis *Confusion Matrix* untuk meminimalisir kesalahan deteksi pada sistem keselamatan penyandang tunarungu.

1.4 Batasan Masalah

Batasan masalah yang didefinisikan dalam penelitian ini adalah sebagai berikut :

1. Dataset yang digunakan adalah dataset sekunder terstandarisasi, yaitu UrbanSound8K, tanpa melakukan perekaman data primer secara manual.
2. Lingkup klasifikasi dibatasi pada kategori suara lingkungan yang merepresentasikan indikator bahaya atau peringatan bagi keselamatan fisik di jalan raya.
3. Fokus penelitian terbatas pada eksperimen pelatihan (*training*) dan evaluasi performa model *Deep Learning*, serta tidak mencakup perancangan perangkat keras (*hardware*), pengembangan antarmuka pengguna (*User Interface*), maupun implementasi sistem secara *real-time*.

1.5 Manfaat Penelitian

Manfaat dari penelitian ini adalah :

1. Memberikan bukti nyata terkait efektivitas metode *Transfer Learning* pada arsitektur PANNs serta perbandingan performa antara representasi input *Raw Waveform*, *Log-mel Spectrogram*, dan *Hybrid* dalam mengatasi

keterbatasan dataset.

2. Berkontribusi dalam pengembangan teknologi asistif berbasis AI yang dapat meningkatkan keselamatan dan kemandirian mobilitas penyandang tunarungu melalui deteksi suara bahaya yang akurat.
3. Menjadi referensi bagi penelitian selanjutnya atau pengembang aplikasi dalam menentukan konfigurasi model yang paling optimal untuk diterapkan pada sistem peringatan dini.

1.6 Sistematika Penulisan

Sistematika penulisan berisi pembahasan apa yang akan ditulis disetiap Bab. Sistematika pada umumnya berupa paragraf yang setiap paragraf mencerminkan bahasan setiap Bab.

Bab I

Bab ini berisikan penjelasan latar belakang dari topik penelitian yang berlangsung, rumusan masalah dari masalah yang dihadapi pada penjelasan di latar belakang, tujuan dari penelitian, batasan dari penelitian, manfaat dari hasil penelitian, dan sistematika penulisan tugas akhir.

Bab II

Bab ini membahas mengenai tinjauan pustaka dari penelitan terdahulu dan dasar teori yang berkaitan dengan penelitian ini.

Bab III

Bab ini berisikan penjelasan alur kerja penelitian, alat dan data yang digunakan, metode yang digunakan, dan metrik pengujian.

Bab IV

Bab ini membahas hasil implementasi dan pengujian dari penelitian yang dilakukan, serta analisis dan evaluasi yang dapat dipetik dari hasil.

Bab V

Bab ini membahas kesimpulan dari hasil penelitian dan juga saran untuk penelitian selanjutnya.

BAB II
TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

2.2 Dasar Teori

Dasar teori ini akan menjadi fondasi utama dalam menyusun metode dalam penelitian ini. Pemaparan diawali dengan membahas mengenai konsep fisika suara, pemrosesan audio digital, serta teknik ekstraksi fitur suara masukan (input) yang digunakan untuk menerjemahkan sinyal audio ke dalam format yang dapat diproses oleh mesin. Selanjutnya, pembahasan akan diarahkan pada inti dari penelitian ini, yaitu arsitektur *Deep Learning* yang digunakan, mekanisme *Transfer Learning*, hingga berbagai strategi optimasi dan regulasi pelatihan model. Sebagai penutup, metrik evaluasi akan diuraikan pada bab ini sebagai bahan analisis untuk menyimpulkan hasil dari penelitian ini.

2.2.1 *Environmental Sound Classification* (ESC)

Fenomena yang terjadi di sekitar lingkungan dapat diidentifikasi, baik melalui visual ataupun akustik (suara). Seiring berkembangnya teknologi kecerdasan buatan (AI), komputer (mesin) memiliki kemampuan untuk berperilaku seperti manusia, salah satu contohnya adalah mampu mengidentifikasi suatu kejadian melalui masukan akustik. *Environmental Sound Classification* (ESC) merupakan klasifikasi kejadian akustik, di mana aktivitas di lingkungan sekitar diidentifikasi dan dikelompokkan sehingga dapat memicu sebuah sistem untuk bekerja (aktif) [9]. Klasifikasi ini memiliki kompleksitas yang lebih rumit dibandingkan dengan jenis klasifikasi akustik lainnya. Pengenalan suara manusia (*speech*) memiliki struktur ejaan dan pengenalan musik memiliki pola ritme dan melodi yang teratur, sedangkan suara lingkungan bersifat tidak statis dan tidak memiliki struktur baku [9]. Hal

tersebut menunjukkan bahwa ESC memiliki batasan dan kompleksitas yang khusus.

Penerapan ESC memiliki manfaat dalam beberapa ruang lingkup (domain), salah satunya adalah pengembangan sistem cerdas. Sistem rumah pintar (*Smart Home*) memanfaatkan tangkapan suara dari mikrofon sebagai masukan dan mengambil tindakan respons atas suara tersebut [10]. Contohnya ketika sistem mendeteksi kaca pecah, maka sistem keamanan akan menyala sebagai respons dari tanda bahaya tersebut. Pada skala ruang yang lebih luas, ESC juga diterapkan pada sistem pemantauan kota pintar (*smart city surveillance*). Teknologi ini membantu infrastruktur kota mendeteksi kejadian darurat di jalan raya secara otomatis melalui sensor akustik [11]. Dari beberapa bentuk penerapan tersebut, penelitian ini membawa pemanfaatan ESC ke dalam lingkup teknologi alat bantu personal (asistif), yaitu pengenalan kejadian akustik darurat perkotaan khusus bagi penyandang disabilitas tunarungu. Keterbatasan visual penyandang tunarungu dapat dijembatani melalui teknologi pengenalan akustik yang diidentifikasi dari segala sudut pandang [9].

Namun, klasifikasi suara lingkungan memiliki tantangan tersendiri. Tantangan tersebut terletak pada variasi jarak pengambilan sampel dan pencampuran dengan kebisingan latar belakang [9]. Oleh karena itu, diperlukan pendekatan komputasi yang kuat, seperti *Deep Learning* untuk mengekstraksi pola inti fitur dan mengatasi variasi akustik pada ESC [6].

2.2.2 Konsep Suara Digital

Pada mulanya, suara yang didengar manusia memiliki sinyal fisik yang tidak dapat dilihat secara langsung. Dengan perangkat pengambil suara, seperti mikrofon, sinyal fisik ditangkap dan dikonversikan menjadi sinyal analog dalam bentuk gelombang kontinu. Sistem komputasi tidak dapat memproses gelombang sinyal kontinu, karena arsitektur mesin hanya beroperasi menggunakan data biner (0 dan 1). Untuk memahami sinyal analog tersebut, diperlukan proses

pencuplikan gelombang secara berkala untuk diubah menjadi deretan nilai diskrit (angka). Proses konversi ini disebut Analog-to-Digital Conversion (ADC) [12]. Hasil dari proses konversi ini berupa deretan sinyal digital yang merepresentasikan nilai diskrit amplitudo gelombang suara pada setiap titik waktu tertentu. Nilai amplitudo inilah yang menjadi fondasi dasar dalam komputasi dan pemrosesan sinyal audio pada mesin.

Adapun tiga komponen utama yang membentuk karakteristik dari suara digital adalah sebagai berikut:

1. ***Sampling Rate* dan Teorema Nyquist**

   Pengambilan seluruh nilai amplitudo tersebut bergantung pada kapasitas perangkat keras dalam mencuplik sampel pada satu rentang waktu. Konsep ini dilambangkan dengan istilah *Sampling Rate*, yaitu jumlah titik sampel yang diambil per detik dari sebuah sinyal audio, dengan satuan Hertz (Hz) [12]. Sebagai contoh, jika sebuah audio memiliki *sampling rate* sebesar 32.000 Hz, maka sistem mengambil 32.000 titik sampel amplitudo dalam 1 detik. Semakin tinggi nilai *sampling rate*, maka semakin akurat rekaman digital tersebut merepresentasikan bentuk gelombang suara aslinya.

   Terkait hal ini, Teorema Nyquist-Shannon mengemukakan aturan matematis bahwa nilai *sampling rate* minimum harus dua kali lipat dari frekuensi tertinggi yang ada pada sinyal suara asli tersebut ($f_s \geq 2f_{max}$) [12]. Aturan ini didasarkan pada konsep frekuensi, yaitu banyaknya gelombang dalam satu detik. Karena satu siklus gelombang penuh harus terdiri dari satu bagian puncak dan satu bagian lembah, Teorema Nyquist memastikan bahwa proses pencuplikan menangkap setidaknya dua titik tersebut agar salah satu bagian gelombang tidak hilang (*aliasing*) saat diubah ke dalam bentuk digital [12].

2. ***Bit Depth***

   Jika *sampling rate* berfokus pada seberapa sering sampel diambil berdasarkan urutan waktu (frekuensi), maka *bit depth* menentukan tingkat

ketelitian atau resolusi dari nilai amplitudo pada setiap sampel tersebut. Semakin tinggi nilai *bit depth*, maka semakin halus transisi volume suara yang dihasilkan, sehingga meminimalisir distorsi atau hilangnya informasi sinyal (*quantization error*) [13].

Rentang nilai diskrit amplitudo ini dikalkulasikan menggunakan persamaan berikut:

- Total kemungkinan nilai pada resolusi n bit = 2^n
- Nilai batas bawah (minimum) n bit = $-2^{(n-1)}$
- Nilai batas atas (maksimum) n bit = $2^{(n-1)} - 1$

Perbedaan rentang antara batas atas dan batas bawah terjadi karena nilai 0 tergolong ke bagian dari nilai positif. Representasi perbedaan ini diatur dalam hukum *Two's Complement* yang merupakan standar fundamental dalam arsitektur komputasi modern [14].

3. **Format Saluran Suara (*Audio Channel*)**

   Karakteristik spasial dari sebuah rekaman audio ditentukan oleh format saluran suaranya. Format ini bergantung pada jumlah perangkat mikrofon yang digunakan serta posisi pengambilan saat proses perekaman [13]. Secara umum, terdapat dua format saluran suara yang paling dasar, yaitu saluran tunggal (*mono*) dan saluran ganda (*stereo*). Format *mono* merekam seluruh sinyal suara ke dalam satu lintasan tunggal, sedangkan format *stereo* menggunakan dua lintasan terpisah (kiri dan kanan) untuk menciptakan ilusi arah dan dimensi ruang pada suara yang dihasilkan [13].

   Dalam proses komputasi, format saluran ini secara langsung memengaruhi dimensi struktur data pada memori mesin. Suara dengan format *mono* direpresentasikan sebagai satu baris deret (*array*) nilai amplitudo, sedangkan suara *stereo* direpresentasikan sebagai dua baris *array* nilai amplitudo terpisah [13]. Dalam tahap prapemrosesan (*preprocessing*) data

untuk pelatihan model kecerdasan buatan (*Deep Learning*), keberagaman format saluran suara dari data mentah seringkali diseragamkan (*down-mixing*) menjadi format *mono* [7]. Hal ini dilakukan untuk menjaga konsistensi dimensi data input pada model dan meminimalkan beban komputasi tanpa menghilangkan fitur utama dari sinyal suara tersebut.

2.2.3 Dataset UrbanSound8K

Dataset UrbanSound8K merupakan kumpulan data yang mengandung 8732 suara kejadian di lingkungan perkotaan. Semua file audio di dalam UrbanSound8K berdurasi maksimal 4 detik dan berekstensi `.wav` [5]. UrbanSound8K mengelompokkan label datanya ke dalam 10 kelas, di mana kategori tersebut mencakup :

1. air conditioner (pendingin ruangan)
2. car horn (klakson mobil)
3. children playing (anak-anak sedang bermain)
4. dog bark (gonggongan anjing)
5. drilling (aktivitas mengebor)
6. engine idling (mesin menyala statis)
7. gun shot (tembakan senjata)
8. jackhammer (penghancur permukaan keras)
9. siren (sirene)
10. street music (musik jalanan)

Selain file audio, dataset ini juga menyediakan file `.csv` sebagai informasi metadata untuk setiap file audionya. Terdapat format penamaan file audio di dalam file metadata tersebut dengan format : `[fsID]-[classID]-[occurrenceID]-[sliceID].wav`. Penomoran `classID` dimulai dari angka 0 sampai 9, sesuai dengan urutan yang tertera di atas [5].

Semua file audio telah disusun ke dalam 10 fold, dengan format penamaan

folder : ‘fold1‘ - ‘fold10‘. Penyusunan ini dibuat sedemikian rupa karena ada beberapa file audio yang direkam di tempat dan kejadian yang sama, sehingga beberapa rekaman tersebut disatukan pada fold yang sama demi menghindari kebocoran data. Kebocoran data merupakan fenomena yang terjadi saat data yang seharusnya menjadi data uji, tercampur dengan data latih sehingga model mendapatkan karakteristik suara yang sama saat validasi pembelajaran (dan berlaku sebaliknya). Maka dari itu, pembuat dataset sangat tidak menganjurkan pengacakan data ulang karena berpotensi mengakibatkan model mengalami overfitting, yaitu model memiliki nilai akurasi tinggi hanya saat memprediksi data latihnya saja [5]. Ketika diberikan data baru yang belum pernah dipelajari sebelumnya, maka model akan gagal memahami data dan mengalami penurunan performa ketika dihadapkan pada suara baru dengan label yang sama.

Dalam dataset UrbanSound8K, file audionya merupakan hasil kompilasi rekaman dari berbagai kontributor di situs repositori Freesound, sehingga *sampling rate*, *bit depth*, dan format saluran suara tidak seragam [5]. Agar model memiliki dimensi input yang sesuai dan seragam, diperlukan tahap prapemrosesan data untuk menyamaratakan dimensi data pada UrbanSound8K.

2.2.4 Prapemrosesan Data

Salah satu kunci utama penentu keberhasilan model kecerdasan buatan dalam tugas klasifikasi adalah kualitas data yang digunakan [15]. Mengingat tingginya variasi karakteristik fisik audio pada dataset mentah UrbanSound8K, tahap prapemrosesan (*preprocessing*) data perlu dilakukan sebelum data tersebut digunakan untuk pelatihan model. Tahapan ini bertujuan untuk menyamaratakan karakteristik kualitas data sesuai dengan kebutuhan input model untuk mendapatkan hasil performa maksimal [15].

Adapun tahapan prapemrosesan data yang diterapkan pada sinyal suara digital dijelaskan sebagai berikut:

1. ***Down-mixing***

Down-mixing merupakan teknik pemrosesan sinyal untuk mereduksi jumlah saluran suara, yang dalam konteks ini melakukan konversi format *stereo* menjadi format *mono*. Pada tugas klasifikasi suara lingkungan, informasi spasial atau arah datangnya suara tidak memiliki relevansi yang signifikan terhadap identitas kelas suara tersebut [7]. Proses reduksi ini dilakukan dengan mengalkulasi nilai rata-rata (*mean*) amplitudo dari saluran kiri dan saluran kanan pada setiap titik sampel waktu yang sama [13]. Persamaan matematis untuk operasi ini dirumuskan sebagai berikut:

$$x_{mono}[n] = \frac{x_{left}[n] + x_{right}[n]}{2}$$

(Rumus 2.1)

Keterangan:

- x : Amplitudo Sinyal
- n : Indeks Waktu
- $x_{mono}[n]$: Amplitudo saluran *mono* pada sampel ke-n.
- $x_{left}[n]$: Amplitudo saluran kiri pada sampel ke-n.
- $x_{right}[n]$: Amplitudo saluran kanan pada sampel ke-n.

Langkah reduksi ini memangkas dimensi struktur data sebesar 50%, yang berdampak langsung pada efisiensi alokasi memori serta meringankan beban komputasi model saat proses pelatihan berlangsung tanpa menghilangkan karakteristik frekuensi utama dari sinyal tersebut [7].

2. ***Resampling***

   Resampling adalah proses transformasi digital untuk mengubah *sampling rate* dari suatu sinyal audio [12]. Dalam konteks tugas klasifikasi, proses ini sangat krusial karena arsitektur model klasifikasi mensyaratkan dimensi input yang seragam. Jika dataset terdiri dari berbagai rekaman audio dengan *sampling rate* yang bervariasi (misalnya 16.000 Hz, 44.100 Hz, 48.000 Hz), model akan kesulitan memproses panjang *array* yang berbeda-

beda untuk durasi rekaman yang sama. Oleh karena itu, seluruh audio mentah tersebut harus diseragamkan ke satu nilai *sampling rate* standar. Demi menjaga karakteristik suara, proses *resampling* harus tetap mematuhi Teorema Nyquist-Shannon yang telah diuraikan sebelumnya. Hal ini bertujuan agar frekuensi tertinggi yang merepresentasikan karakteristik utama suara tidak hilang atau mengalami distorsi (*aliasing*) [12].

3. **Penyeragaman Durasi (*Zero-Padding* dan *Truncating*)**

   Karakteristik model klasifikasi pada umumnya mensyaratkan dimensi input yang bernilai tetap (*fixed-length*) untuk dapat memproses data tersebut [16]. Panjang rekaman audio yang bervariasi menghasilkan panjang *array* sinyal digital yang tidak seragam, sehingga model akan gagal melakukan komputasi jika data mentah tersebut dimasukkan.

   Untuk mengatasi inkonsistensi durasi ini, diterapkan teknik *zero-padding* pada sinyal yang berdurasi lebih pendek dari target durasi input, dan *truncating* (pemotongan) pada sinyal yang melebihi target. *Zero-padding* adalah metode penambahan deret nilai amplitudo nol, yang berarti keheningan (*silence*) pada bagian ujung akhir *array* sinyal audio [17]. Karena nilai nol merepresentasikan ketiadaan suara, penambahan ini memperpanjang durasi audio tanpa mengubah karakteristik frekuensi maupun informasi dari sinyal aslinya.

   Secara matematis, operasi *zero-padding* untuk memperpanjang sinyal audio dirumuskan sebagai berikut [17]:

$$x_{pad}[n] = \begin{cases} x[n], & \text{untuk } 0 \leq n < L \\ 0, & \text{untuk } L \leq n < T \end{cases}$$

(Rumus 2.2)

   Keterangan:

   - x : Amplitudo Sinyal
   - n : Indeks waktu diskret (sampel)

- $x[n]$: Nilai amplitudo pada sampel ke-n
- $x_{pad}[n]$: Nilai amplitudo target pada sampel ke-n
- L : Panjang sinyal awal (jumlah sampel)
- T : Panjang sinyal target (jumlah sampel)

Melalui standarisasi ini, seluruh data audio memiliki dimensi ruang yang seragam sehingga kompatibel dengan persyaratan input arsitektur model klasifikasi dan siap untuk diekstraksi fiturnya.

2.2.5 Representasi Input Suara

Setelah menjalani seluruh tahap prapemrosesan, dilakukan pembentukan representasi input untuk model yang dikenal sebagai ekstraksi fitur. Sinyal audio digital dalam bentuk mentah, yang disebut *Raw Waveform*, merupakan deretan nilai amplitudo satu dimensi (1D) yang diurutkan berdasarkan indeks waktu. Meskipun kaya akan informasi, representasi mentah ini mengandung dimensi deretan nilai yang sangat besar dan dinamika amplitudo yang cukup kompleks sehingga dapat menyulitkan model klasifikasi dalam menemukan pola inti pada sinyal [18]. Untuk menonjolkan inti karakteristik suara, serangkaian proses transformasi matematis buatan (*hand-crafted features*) diterapkan pada *Raw Waveform* untuk diubah ke dalam representasi berdomain frekuensi, yaitu *Log-mel Spectrogram* [18]. Representasi ini memproyeksikan sinyal ke dalam bentuk dua dimensi (2D) dengan pemetaan nilai frekuensi pada setiap indeks waktu, sehingga informasi sinyal audio lebih mudah untuk dipelajari. Meski memudahkan pemrosesan, representasi ini tidak menyajikan informasi yang lengkap akibat tahapan reduksi informasi melalui transformasi matematis buatan tersebut. Dimensi representasi input yang berbeda ini dapat memengaruhi cara arsitektur model klasifikasi mengekstraksi pola serta beban komputasinya.

2.2.5.1 *Raw Waveform*

Raw Waveform merupakan representasi digital satu dimensi (1D) yang berisikan deretan nilai diskrit amplitudo pada audio, yang jika divisualisasikan akan membentuk sebuah gelombang audio tersebut. Audio dengan representasi tersebut umumnya memiliki format ekstensi berupa `.wav`, yang berisikan data PCM (*Pulse-Code Modulation*) berupa representasi sinyal digital yang belum terkompresi (*lossless*). Format tersebut menandakan kualitas serta informasi pada audio tersebut masih murni dan lengkap. Semua file audio pada UrbanSound8K memiliki format `.wav`, sehingga keutuhan informasi akustik terjaga pada dataset ini.

Gelombang sinyal suara yang sudah mengalami konversi digital, direpresentasikan ke dalam bentuk *array* dengan dimensi berdasarkan indeks durasinya. Total dimensi panjang *array* (N) pada *Raw Waveform* merupakan hasil kali antara durasi rekaman dalam detik (T) dengan *sampling rate* (f_s). Nilai amplitudo dapat berupa nilai positif bahkan negatif yang umumnya berada pada rentang -1 sampai 1 [17]. Semakin jauh nilai tersebut dari titik nol, maka intensitas suara yang dihasilkan semakin tinggi (kencang).

2.2.5.2 *Log-mel Spectrogram*

Spectrogram merupakan representasi grafis fitur suara dalam bentuk domain frekuensi dan waktu. Proses pembentukan *spectrogram* diawali dengan bentuk *raw waveform* yang diproses dengan metode *Short-Time Fourier Transform* (STFT). Metode tersebut dilatarbelakangi oleh masalah mengenai cara dekomposisi setiap frekuensi yang ada pada sebuah gelombang suara. Cara kerja metode STFT adalah dengan memotong audio menjadi bingkai-bingkai waktu yang sangat pendek (milidetik), lalu menerapkan transformasi Fourier pada setiap bingkai secara berurutan untuk mengekstraksi spektrum frekuensinya [19]. Rangkaian spektrum dari setiap bingkai ini kemudian disusun secara temporal membentuk representasi visual dua dimensi.

Setelah mendapatkan gabungan spektrum frekuensi tersebut, skala frekuensi yang digunakan masih berupa skala linear (teratur) dan tidak sesuai dengan pendengaran manusia. Pada kenyataannya, telinga manusia sangat sensitif membedakan nada rendah (misal membedakan 100 Hz dan 200 Hz), tetapi sangat susah membedakan nada tinggi (10.000 Hz dan 10.100 Hz terdengar sama saja). Maka dari itu, Skala Mel (*Mel-Scale*) digunakan untuk mengubah resolusi pembacaan frekuensi suara agar menyerupai persepsi pendengaran manusia, sehingga membuat representasi fitur suara menjadi lebih realistis [19]. *Spectrogram* yang telah diproses dengan *Mel-Scale* disebut *Mel-Spectrogram*.

Namun, proyeksi pada *Mel-Spectrogram* masih memberikan rentang intensitas suara yang cukup jauh, sehingga grafik hanya menampilkan warna terang pada titik intensitas suara yang cukup tinggi. Ini mengakibatkan nilai warna pada detail minor suara yang ingin dipelajari tidak terproyeksi dengan maksimal, sehingga sulit untuk mengklasifikasi dengan detail yang seharusnya penting pada pendengaran manusia. Maka dari itu, operasi logaritmik menjadi solusi dengan mengompresi rentang dinamis (*dynamic range compression*) nilai amplitudo pada *Mel-Spectrogram*. Seluruh nilai amplitudo pada grafik tersebut dikonversi menggunakan operasi logaritmik ke dalam satuan Desibel (dB) [19]. Proyeksi *Mel-Spectrogram* yang telah diberikan transformasi logaritmik (dapat disebut *Log-mel Spectrogram*) sangat menyerupai pendengaran manusia sehingga mesin dapat mempelajari suara tersebut layaknya manusia mempelajarinya.

2.2.6 Augmentasi Data

Augmentasi data merupakan salah satu teknik yang efektif dalam memperbanyak variasi data dalam ranah pembelajaran mesin (*Machine Learning*). Variasi tersebut dilakukan dengan cara memanipulasi bagian data, seperti menambahkan gangguan (*noise*) atau melakukan pemotongan durasi secara acak. Proses augmentasi dilakukan secara dinamis pada setiap iterasi pelatihan, sehingga model mendapatkan variasi data yang selalu baru. Teknik

ini berguna untuk mencegah model menghafal data latih (*overfitting*). Dengan demikian, model memiliki tingkat generalisasi yang tinggi, yakni kemampuan model untuk memprediksi dengan benar pada data yang belum pernah didapatkan saat pelatihan sebelumnya.

Pada penelitian ini, teknik augmentasi yang digunakan berfokus pada ranah temporal, yaitu pemotongan durasi audio secara acak (*Random Cropping*).

2.2.6.1 *Random Cropping*

Random Cropping pada audio adalah teknik memperluas variasi data yang beroperasi pada domain waktu (temporal) dengan cara mengambil potongan data audio dengan durasi yang lebih pendek dari durasi keseluruhan sinyal input. Teknik ini diterapkan pada setiap iterasi pelatihan, diawali dengan memilih titik awal pemotongan secara acak (t_0), dengan t_c sebagai panjang durasi pemotongan. Penempatan titik awal pemotongan diperbolehkan pada rentang durasi $0 \leq f_0(n) \leq T - n$ di mana T merupakan total keseluruhan durasi audio. Pengambilan cuplikan secara acak ini memaksa model klasifikasi untuk tidak terpaku pada posisi absolut suatu fitur suara, melainkan belajar mengenali pola suara tersebut terlepas dari waktu kemunculannya [5].

2.2.7 *Convolutional Neural Network* (CNN)

Convolutional Neural Network (CNN) adalah arsitektur model *Deep Learning* berupa jaringan saraf yang bekerja dengan cara mengenali pola pada data dan meringkas informasi penting yang didapatkan melalui setiap lapisannya. CNN dikenal karena keunggulannya dalam mempelajari dan mengenali gambar (2D). Arsitektur ini bekerja dengan memanfaatkan operasi matematika (konvolusi) dengan menggerakkan sebuah kernel konvolusi (filter) berukuran tertentu ke sebuah gambar, sehingga didapatkan representasi fitur baru yang dikenal sebagai peta fitur (*feature map*).

Arsitektur CNN dibagi menjadi dua bagian besar, yaitu lapisan ekstraksi

fitur (*Feature Extraction Layer*) dan lapisan klasifikasi (*Classification Layer*). *Feature Extraction Layer* merupakan lapisan yang menerima dan mengekstraksi fitur input yang telah diberikan ke dalam peta fitur (*Feature Map*) multidimensi. Pada tahap akhir ekstraksi, peta fitur tersebut diratakan (*flatten*) menjadi vektor satu dimensi (1D). *Classification Layer* akan memproses hasil vektor dari lapisan sebelumnya dan melakukan klasifikasi terhadap fitur-fitur tersebut ke dalam kelas yang telah dipetakan.

2.2.7.1 *Kernel* dan *Stride*

Kernel (filter) adalah komponen berupa matriks 2 dimensi yang berisi nilai-nilai bobot (*weights*). Umumnya ukuran *kernel* yang digunakan berupa persegi 3×3, 5×5, dan 7×7. Saat lapisan ekstraksi bekerja, komponen ini terus bergeser menimpa gambar dan mengkalkulasikan nilai di dalam kernel dengan nilai *pixel* gambar di bawahnya dengan operasi perkalian titik (*dot product*). Hasil operasi tersebut dijumlahkan menjadi satu nilai baru pada *feature map*. Melalui banyaknya iterasi pelatihan, nilai bobot awal terus diperbarui dari evaluasi pelatihan. Kemampuan ini yang membuat model dapat mengekstraksi pola fitur penting pada gambar.

Stride merupakan mekanisme yang mendukung *kernel* dalam pengaturan langkah pergeseran dengan nilai tertentu. Jika *stride* bernilai 2, maka *kernel* akan bergeser dengan jarak sebesar 2 *pixel*. Semakin besar nilai *stride* yang ditetapkan, maka ukuran dimensi spasial pada *feature map* semakin menyusut. Mekanisme ini penting dalam menjaga beban komputasi dan memori yang tidak berlebihan pada lapisan berikutnya.

2.2.7.2 *Batch Normalization* (BN)

Nilai-nilai yang telah dipetakan ke dalam *feature map* pada setiap lapisannya memiliki rentang dinamika nilai yang tidak teratur pada kumpulan representasi fiturnya (*batch*). Hal tersebut menyebabkan arah pembelajaran

model menjadi tidak stabil dan memperlambat proses pencapaian nilai optimal, sehingga diperlukan proses normalisasi pada kumpulan nilai tersebut.

Batch Normalization (BN) merupakan mekanisme normalisasi rentang nilai yang diperoleh dari setiap *feature map* sebelum diproses oleh lapisan selanjutnya. Normalisasi tersebut dilakukan dengan mengurangkan setiap nilai fitur dengan rata-rata (*mean*) dari *batch* tersebut, kemudian membaginya dengan standar deviasi. Tujuan dari operasi ini adalah untuk memetakan rata-rata nilai *batch* menjadi nol dan variansi nilai menjadi satu. Mekanisme ini menghasilkan nilai fitur yang lebih mudah untuk diproses menuju lapisan berikutnya.

Setelah nilai dinormalisasikan, BN memiliki dua parameter yang dapat dipelajari, yaitu skala (γ) dan pergeseran (β). Kedua parameter tersebut berfungsi untuk memanipulasi ulang rentang nilai tersebut jika dibutuhkan oleh lapisan selanjutnya.

2.2.7.3 *Rectified Linear Unit* (ReLU)

Rectified Linear Unit (ReLU) merupakan fungsi aktivasi non-linear yang mengubah nilai negatif pada peta fitur menjadi nol. Fungsi tersebut berisikan persamaan matematis sederhana berupa $f(x) = \max(0, x)$, di mana x adalah nilai awal yang dibandingkan dengan nilai nol. Jika nilai x bernilai positif ($x > 0$), maka nilai tersebut dipertahankan ($f(x) = x$). Sebaliknya, jika x bernilai negatif atau batas nol ($x \leq 0$), maka nilainya diubah menjadi nol.

Operasi pada lapisan konvolusi dengan komponen *Kernel* dan *Stride* bersifat linear, yang hanya mengandung operasi perkalian dan penjumlahan. Jika proses ekstraksi tersebut tidak diberi fungsi aktivasi, maka model tersebut hanya bersifat satu model regresi linear besar yang tidak mampu memahami pola-pola kompleks dan non-linear pada data. Dengan adanya fungsi ReLU, proses ekstraksi fitur menghasilkan nilai spesifik dan memudahkan komputasi pada lapisan model.

2.2.7.4 *Max Pooling*

Max Pooling merupakan salah satu teknik *Pooling* yang mengurangi dimensi data dengan memangkas ukuran spasial peta fitur (*feature map*). Pengurangan dimensi tersebut membuat model benar-benar mempelajari inti fitur, sehingga menghindari model mengalami *overfitting* serta mengurangi beban komputasi memori. Mekanisme *Max Pooling* bekerja menggunakan sebuah jendela berukuran tertentu yang bergeser di atas *feature map*. Pada setiap area yang disorot oleh jendela tersebut, mekanisme ini hanya mengambil satu nilai terbesar dan membuang nilai di sekitarnya.

Pada data gambar atau *spectrogram* suara, nilai piksel yang besar merepresentasikan fitur yang paling tajam, di mana dalam *spectrogram* berarti sinyal suara yang paling dominan. Penggunaan *Max Pooling* akan mempertahankan fitur penting tersebut, sehingga karakteristik sinyal suara yang kuat tidak akan hilang walaupun dimensi data semakin mengecil. Selain itu, mekanisme pengambilan nilai maksimal ini membuat model memiliki sifat kebal terhadap pergeseran posisi fitur (*Translation Invariance*) pada data *spectrogram*.

2.2.7.5 *Fully Connected Layer*

Fully Connected (FC) *Layer* merupakan lapisan pada bagian *Classification Layer* yang berperan dalam pengambilan keputusan klasifikasi akhir. Syarat utama input pada lapisan ini adalah data harus berbentuk vektor satu dimensi (1D). Oleh karena itu, *feature map* pada lapisan konvolusi sebelumnya yang berbentuk multidimensi diratakan menjadi satu deret baris data melalui proses *flattening*. Proses *flattening* ini dilakukan karena lapisan FC tidak melihat posisi titik fitur secara spasial, melainkan hanya perlu melihat keberadaan kumpulan titik fitur yang menjadi ciri karakteristiknya.

Berbeda dengan lapisan konvolusi yang hanya melihat sebagian kecil area, lapisan FC menghubungkan setiap titik neuron dari lapisan sebelumnya dengan seluruh neuron pada lapisan berikutnya secara penuh (*fully connected*). Cara

kerja dari lapisan ini adalah menggabungkan seluruh inti fitur pada lapisan-lapisan sebelumnya untuk mempelajari kombinasi non-linear untuk keputusan akhir. Hasil dari lapisan ini merupakan nilai setiap kelas karakteristik yang ditentukan dengan representasi angka mentah (*logits*).

2.2.7.6 *Sigmoid*

Logits yang dihasilkan oleh lapisan FC masih memiliki nilai ekstrem, di mana angka ini tidak memiliki batasan rentang nilai. Oleh karena itu, digunakan fungsi aktivasi *Sigmoid* yang memetakan hasil angka mentah tersebut ke dalam rentang probabilitas yang ketat, yaitu 0 hingga 1. Mekanisme *Sigmoid* digambarkan melalui operasi matematis berikut:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

(Rumus 2.3)

Keterangan:

- x : Nilai *logits* dari lapisan FC
- e : Bilangan Euler (2.718)
- $\sigma(x)$: Keluaran nilai *sigmoid* dari *logits* x.

Operasi yang dilakukan oleh fungsi ini menghitung probabilitas setiap kelas secara independen, sehingga memungkinkan suatu masukan data memiliki probabilitas tinggi pada lebih dari satu label kelas secara bersamaan. Maka dari itu, fungsi ini umumnya digunakan dalam kasus klasifikasi *multi-label*.

2.2.7.7 *Softmax*

Softmax adalah fungsi aktivasi yang mengubah nilai *logits* dari lapisan FC menjadi distribusi probabilitas. Berbeda dengan *Sigmoid* yang memproses setiap kelas secara independen, *Softmax* mengevaluasi nilai satu kelas dengan membandingkannya terhadap seluruh kelas yang ada. Oleh karena itu, total keseluruhan probabilitas dari semua kelas ditetapkan berjumlah 1 (100%). Jika

nilai probabilitas pada satu kelas bernilai tinggi, maka secara otomatis nilai probabilitas pada kelas lainnya akan menurun menyesuaikan sisa dari total keseluruhan probabilitas.

Cara kerja *Softmax* direpresentasikan ke dalam operasi matematis berikut:

$$f(x_i) = \frac{e^{x_i}}{\sum_{j=1}^{K} e^{x_j}}$$

(Rumus 2.4)

Keterangan:

- x_i : Nilai *logits* untuk kelas ke-i.
- e : Bilangan Euler (2.718)
- K : Total jumlah kelas
- $\sum$: Simbol penjumlahan dari seluruh nilai eksponensial *logits* kelas yang ada.

Dengan mekanisme tersebut, fungsi *Softmax* menjadi standar mutlak untuk kasus klasifikasi *single-label* dengan multikelas.

2.2.8 *Pre-trained Audio Neural Networks* (PANNs)

Dalam dunia pre-trained model, *Pre-trained Audio Neural Networks* (PANNs) menjadi salah satu pilihan yang menyediakan model klasifikasi suara dengan bobot terlatih dari dataset suara berskala besar (AudioSet). Arsitektur ini dikembangkan dan dilatih oleh Kong *et al.* (2020) yang menghasilkan keluaran klasifikasinya berupa *multi-label* (*Multi-label Classification*) ke dalam 527 kelas suara [7]. Oleh karena itu, diperlukan penyesuaian pada lapisan akhir model agar dapat menghasilkan *output* yang sesuai dengan target kelas suara pada penelitian ini.

Penelitian Kong *et al.* mengenai PANNs juga telah mengevalusi performa setiap arsitektur menggunakan tiga metrik utama, yaitu *mean Average Precision* (mAP), *Area Under the Curve* (AUC), dan *d-prime*. Semua arsitektur yang

tergabung dalam PANNs memiliki representasi input yang berbeda-beda. Arsitektur PANNs dengan representasi input satu dimensi (1D) meliputi DaiNet, LeeNet, Res1dNet, dan Wavegram-CNN. Selanjutnya, arsitektur dengan representasi input dua dimensi (2D) meliputi CNN, ResNet, dan MobileNet. Terakhir, satu-satunya arsitektur dengan pendekatan input hibrida (*hybrid*) adalah Wavegram-Logmel-CNN. Dalam penelitian ini, akan diambil 3 model unggul yang mewakili representasi inputnya masing-masing, yaitu Res1dNet31, ResNet38, dan Wavegram-Logmel-CNN14.

2.2.8.1 Res1dNet31

Res1dNet31 merupakan arsitektur ResNet (*Residual Network*) 1 dimensi milik PANNs yang paling unggul dalam menangani representasi input domain waktu dibandingkan model lainnya dengan jenis input yang sama. Arsitektur ini menerima *input* berupa sinyal digital 1 dimensi (*Raw Waveform*) dengan *sampling rate* 32 kHz. Keunggulan arsitektur ini adalah kemampuannya dalam mempelajari fitur data suara mentah yang diperoleh secara alami dibandingkan fitur *Logmel-Spectrogram* yang sudah diproses dengan metode buatan manusia (STFT dan Logmel).

Proses komputasinya diawali dengan mengekstrak fitur *Raw Waveform* menggunakan lapisan konvolusi awal dengan *kernel* berukuran 3 dan *stride* bernilai 5. Informasi diproses lebih dalam melalui *backbone* (jaringan pengekstraksi fitur utama) ResNet dengan 14 blok residu (blok dengan fitur jalur pintas, atau *skip connection*), di mana setiap blok terdiri dari 2 lapisan konvolusi residu yang masing-masing mengandung dilatasi (perluasan jangkauan *kernel*) 1 dan 2. Akhirnya, hasil dari *backbone* dilanjutkan ke 2 lapisan terakhir untuk mendapatkan kesimpulan klasifikasi final. Seluruh lapisan pada arsitektur ini berjumlah 31 lapisan.

2.2.8.2 ResNet38

ResNet38 merupakan salah satu arsitektur ResNet 2 dimensi milik PANNs dengan nilai mAP tertinggi dalam menangani jenis input dengan dimensi tersebut. Berbeda dengan Res1dNet31, arsitektur ini menerima input berupa *Raw Waveform* yang nantinya akan diekstrak dan diproses menjadi *Log-mel Spectrogram* (2D) dengan 1000 *frames* dan 64 *mel bins*.

Arsitektur model diawali dengan dua blok konvolusi 64 *filter*[1] berukuran 3×3 dan mengandung *Batch Normalization* (BN) serta ReLU. Kemudian, *Max Pooling* berukuran 2×2 diterapkan setelah dua blok tersebut. Selanjutnya, fitur dimasukkan ke dalam *backbone* yang berisikan 16 *Basic Blocks*, yang masing-masing berisikan *kernel*, BN, dan ReLU. Kumpulan 16 blok tersebut terdiri dari beberapa kelompok blok berurutan, yaitu 3 *Basic Blocks* 64 *filter*, 4 *Basic Blocks* 128 *filter*, 6 *Basic Blocks* 256 *filter*, dan 3 *Basic Blocks* 512 *filter*. Setiap akhir kelompok blok tersebut akan diterapkan lapisan *Max Pooling* berukuran 2×2. Pada akhir *backbone*, diterapkan dua blok berisikan 2048 *filter* berukuran 3×3, BN, dan ReLU, serta diakhiri dengan penerapan lapisan *Global Pooling*. Sebagai lapisan klasifikasi, *Fully Connected Layer* (FC) 2048 *neuron* dengan ReLU diterapkan, dilanjutkan dengan lapisan FC terakhir berisi 527 *neuron* berserta fungsi aktivasi *Sigmoid* sebagai penentu kesimpulan akhir.

Keunggulan arsitektur ini terletak pada kemampuannya dalam menangani *input* domain frekuensi yang sudah tergambar dalam grafis multidimensi. Hal ini dapat memudahkan arsitektur mengenali pola yang sudah diproses sedemikian rupa sehingga menyerupai pendengaran manusia.

[1]Pada tabel arsitektur di naskah publikasi asli PANNs, terdapat kesalahan penulisan (*typographical error*) yang mencantumkan angka 512 *filter* pada lapisan awal. Berdasarkan urutan kelogisan arsitektur ResNet serta repositori kode sumber resmi PANNs, jumlah *filter* awal yang akurat adalah 64.

2.2.8.3 Wavegram-Logmel-CNN14

Wavegram-Logmel-CNN14 merupakan arsitektur dengan pendekatan hibrida (*hybrid*) pada keluarga PANNs yang diperkenalkan oleh Kong *et al.* dalam penelitiannya. Arsitektur ini menerima input *Raw Waveform* yang diproses dalam dua pendekatan secara bersamaan, yaitu pembentukan *Wavegram* dan *Log-mel Spectrogram*.

Untuk membentuk *Wavegram*, lapisan awal memproses *input* menggunakan lapisan konvolusi CNN 1 dimensi dengan panjang *kernel* 11 dan *stride* 5. Lalu diikuti dengan 3 blok konvolusi 1 dimensi, di mana setiap blok mengandung 2 lapisan konvolusi residu dengan dilatasi bernilai 1 dan 2. Fitur yang dihasilkan kemudian dibentuk ulang (*reshape*) menjadi sebuah *Wavegram*, bersamaan dengan ekstraksi fitur *Log-mel Spectrogram*. Kedua representasi fitur dua dimensi ini nantinya akan digabungkan dan diproses melalui *backbone* arsitektur CNN14.

Penggabungan kedua pendekatan ini berfungsi untuk menutupi kekurangan masing-masing metode. Sinyal *Raw Waveform* murni yang kaya akan informasi namun lebih sulit dipelajari oleh model, dikombinasikan dengan *Log-mel Spectrogram* yang proyeksi polanya lebih mudah dipelajari, meskipun rentan kehilangan sebagian detail informasi akibat proses transformasi matematis.

BAB III
METODE PENELITIAN

3.1 Alur Penelitian

Penelitian ini dilaksanakan melalui serangkaian tahapan sistematis guna memastikan model klasifikasi suara ancaman bahaya yang dikembangkan dapat bekerja optimal pada domain keselamatan penyandang tunarungu. Diagram alur penelitian ditunjukkan pada Gambar 3.1.

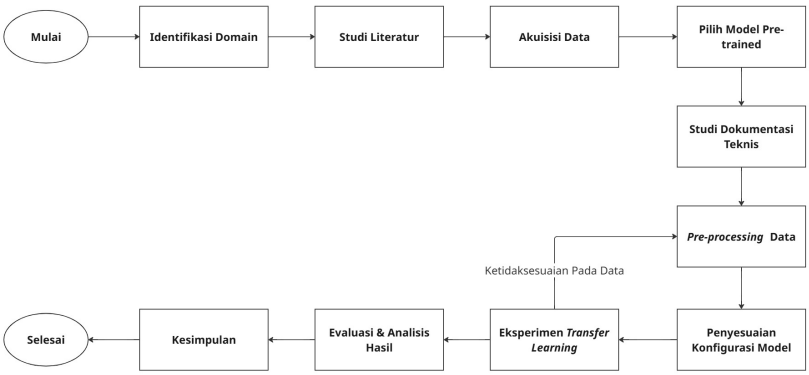

Gambar 3.1 Diagram Alur Penelitian

Penjelasan rinci mengenai tahapan penelitian adalah sebagai berikut:

1. **Identifikasi Domain Penelitian**

   Tahap awal dilakukan dengan mencari referensi domain penelitian untuk klasifikasi suara. Berdasarkan pertimbangan ketersediaan dataset dan urgensi model klasifikasi, domain yang dipilih adalah domain keselamatan publik yang difokuskan untuk alat bantu penyandang tunarungu.

2. **Studi Literatur**

   Dilakukan kajian literatur mendalam untuk menemukan urgensi penelitian, khususnya mengenai kebutuhan teknologi asistif yang mampu mengurangi

risiko kecelakaan bagi penyandang tunarungu melalui pengenalan sinyal bahaya. Ini menjadi landasan teoritis bagaimana teknologi klasifikasi suara dapat menjadi solusi yang efektif dalam mengatasi permasalahan tersebut.

3. **Identifikasi dan Akuisisi Data**

   Akuisisi data dilakukan dengan mengambil dataset sekunder yang sudah terstandarisasi, yaitu UrbanSound8K [5]. Akuisisi data primer tidak dilakukan demi menghindari *device bias* akibat perekaman dataset dengan perangkat non-standar (seperti smartphone) serta kendala regulasi keamanan pada perekaman kelas *gun_shot*. Dari dataset tersebut, dilakukan seleksi kelas sinyal bahaya dengan strategi antisipasi terhadap kendala ketidakseimbangan data (*imbalanced data*) yang telah disiapkan sejak awal.

4. **Pemilihan Model *Pre-trained***

   Mengingat keterbatasan data berisiko menyebabkan kegagalan pelatihan *from scratch*, digunakan pendekatan *Transfer Learning* dengan memanfaatkan model *Pre-trained*. Tiga varian arsitektur PANNs (*Pre-trained Audio Neural Networks*) [7] dipilih untuk mewakili domain input yang berbeda, yaitu *Res1dNet31* (domain waktu), *ResNet38* (domain frekuensi), dan *Wavegram-Logmel-CNN* (*hybrid*). Arsitektur PANNs dipilih karena telah dilatih pada dataset masif (AudioSet) dan memiliki performa yang teruji.

5. **Studi Dokumentasi Teknis**

   Tahap ini mempelajari karakteristik data dan model yang digunakan. Fokus utama dalam tahap ini adalah memahami mekanisme pembagian data (fold) pada dataset guna mencegah kebocoran data (*data leakage*) dan mempelajari variasi representasi input pada arsitektur PANNs untuk menentukan skenario komparasi yang tepat.

6. ***Pre-processing* Data**

   Serangkaian proses dilakukan untuk mengubah data mentah menjadi format yang siap latih, meliputi penanganan struktur *fold*, seleksi kelas, dan penyesuaian format audio, serta penerapan teknik augmentasi temporal berupa *random cropping* untuk menstandarisasi durasi input.

7. **Penyesuaian Konfigurasi Model**

   Dilakukan modifikasi pada arsitektur model agar sesuai dengan tujuan klasifikasi 4 kelas bahaya, serta penerapan strategi untuk menangani ketidakseimbangan data.

8. **Eksperimen *Transfer Learning***

   Tahapan ini menjadi tahapan inti di mana model dilatih ulang (*fine-tuning*) untuk mengenali karakteristik suara spesifik. Proses ini mencakup eksperimen *hyperparameter* dan pelatihan ketiga variasi model untuk menemukan konfigurasi parameter pelatihan yang paling optimal. Proses ini bersifat iteratif. Apabila performa model belum mencapai target yang diharapkan, maka akan dilakukan penyesuaian ulang pada tahap *pre-processing* data untuk melakukan penyesuaian data dan melakukan pelatihan kembali hingga diperoleh model yang optimal.

9. **Evaluasi dan Analisis Hasil**

   Performa model hasil *fine-tuning* dievaluasi menggunakan metrik *F1-Score*, nilai *Loss*, dan analisis *Confusion Matrix*. Evaluasi ini bertujuan untuk membandingkan dan menganalisis performa antara ketiga model dalam melakukan klasifikasi suara ancaman bahaya.

10. **Kesimpulan**

    Berdasarkan hasil evaluasi, dilakukan perbandingan komparatif untuk menyimpulkan model mana yang memiliki performa paling unggul dan stabil.

3.2 Pengumpulan dan Prapemrosesan Data

Sumber data utama dalam penelitian ini adalah dataset publik **UrbanSound8K** [5]. Dataset ini diunduh dalam format terkompresi (`.zip`). Setelah diekstraksi, struktur dataset terdiri dari 10 folder (masing-masing mewakili satu *fold*) beserta satu file metadata (`.csv`) yang memuat informasi nama file audio, *class ID*, dan *fold* asal.

Namun, dataset mentah ini memerlukan serangkaian penyesuaian agar relevan dengan konteks keselamatan penyandang tunarungu. Mengingat dataset ini awalnya berisi 10 kelas suara umum di perkotaan yang tersebar dalam 10 *fold*, penelitian ini memfokuskan pada seleksi kelas bahaya spesifik serta menyusun ulang data menjadi 5 fold eksperimen. Sebagai langkah antisipasi terhadap keterbatasan data setelah seleksi kelas, strategi augmentasi temporal diterapkan untuk memperkaya variasi data latih. Oleh karena itu, tahap prapemrosesan data menjamin integritas data dan mencegah kebocoran informasi (*data leakage*) selama proses pelatihan, sebagaimana dijabarkan pada tahapan berikut.

3.2.1 Seleksi Kelas

Tidak seluruh kelas pada dataset UrbanSound8K relevan dengan konteks keselamatan tunarungu. Oleh karena itu, dilakukan penyaringan untuk hanya mengambil 4 kelas prioritas yang merepresentasikan sinyal bahaya, yaitu:

1. ***gun_shot* (Tembakan)**

   Suara tembakan senjata api merupakan sinyal bahaya dengan tingkat fatalitas yang sangat tinggi. Walaupun kejadiannya jarang terjadi, khususnya di Indonesia, deteksi suara ini menjadi langkah mitigasi risiko yang baik dalam melindungi penyandang tunarungu.

2. ***siren* (Sirine)**

   Suara sirine menandakan keberadaan kendaraan prioritas (ambulans, pemadam kebakaran, atau patroli polisi) yang sering kali melaju dengan kecepatan tinggi dan memiliki hak prioritas jalan. Dengan deteksi suara

tersebut, pengguna dapat mengambil langkah untuk segera menepi dan menghindari jalur lintasan kendaraan tersebut.

3. ***dog_bark* (Gonggongan Anjing)**

   Suara anjing yang menggonggong berpotensi menjadi sinyal bahaya, terutama jika anjing tersebut berupa anjing liar yang dapat menyerang secara tiba-tiba. Dengan mendeteksi suara ini, pengguna dapat langsung mengetahui di mana posisi anjing tersebut dan mengambil langkah untuk antisipasi ancaman.

4. ***car_horn* (Klakson Mobil)**

   Suara klakson mobil menjadi sinyal penting pada lalu lintas, yang salah satu fungsinya adalah sebagai peringatan dari pengemudi kendaraan tersebut kepada pejalan kaki yang berada di jalur lintasnya. Dengan deteksi ini, pengguna dapat lebih waspada terhadap situasi lalu lintas di sekitarnya.

3.2.2 Strategi Penyusunan Ulang Data (*Fold Mapping*)

Dataset UrbanSound8K secara bawaan terbagi ke dalam 10 *fold*. Untuk efisiensi eksperimen tanpa melanggar aturan independensi data, penelitian ini menyusun ulang 10 *fold* tersebut menjadi 5 *fold* eksperimen baru. Penyusunan ini dilakukan secara berurutan (misalnya Fold 1 dan 2 menjadi Fold Baru 1) tanpa pengacakan data antar *fold*. Teknik penyusunan tersebut memastikan data latih dan data uji tidak tercampur pada fold yang sama, sehingga teknik penyusunan ini menghindari adanya kebocoran data (*data leakage*) yang menyebabkan model menjadi *overfitting*.

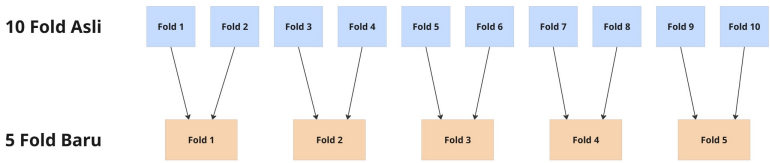

Gambar 3.2 Ilustrasi Strategi Penyusunan Ulang Fold pada Dataset UrbanSound8K

Adapun penyusunan ini didasari oleh dua pertimbangan, yaitu rasio pembagian data yang ideal dan efisiensi sumber daya komputasi. Skema 5-*fold* menghasilkan proporsi 80% data latih dan 20% data uji. Proporsi ini memberikan model evaluasi yang lebih representatif terhadap variasi data daripada skema 10-*fold* bawaan yang menyisakan 10% data uji. Selain memberikan porsi data yang ideal, skema tersebut berdampak mengurangi waktu komputasi pelatihan model tanpa mengurangi validitas pengujian.

Dikarenakan skema baru tersebut, maka mekanisme validasi yang digunakan selanjutnya pada model adalah *5-fold cross validation*. Pada iterasi setiap pengujiannya, satu *fold* dialokasikan sebagai data uji secara bergantian dan empat *fold* sisanya akan digunakan sebagai data latih model. Mekanisme rotasi ini diterapkan agar model selalu diuji dengan data yang berbeda dari yang sudah pernah dipelajari saat proses latih, sehingga hasil evaluasi mencerminkan kemampuan generalisasi yang sebenarnya.

3.2.3 Standarisasi Format Audio

Sebelum data audio dapat diproses oleh model, diperlukan standarisasi format pada data tersebut mengingat data mentah memiliki format yang berbeda-beda. Ketidaksesuaian format input dapat menyebabkan kegagalan pada proses ekstraksi fitur, bahkan pelatihan model. Oleh karena itu, standarisasi format menjadi langkah penting untuk memastikan bahwa semua data audio memiliki

format yang konsisten dan sesuai dengan kebutuhan model, di mana langkah-langkah tersebut mencakup :

1. **Konversi *Channel* Audio (*Down-mixing*)**

   Langkah ini diterapkan karena terdapat beberapa data audio pada Dataset UrbanSound8K dengan format stereo (dua saluran). Untuk menyeragamkan dimensi input pada model nanti, seluruh data audio dikonversi menjadi format mono (satu saluran). Proses *down-mixing* ini menggunakan persamaan **Rumus 2.1** pada Bab II.

   Konversi ini dilakukan untuk menyederhanakan representasi suara untuk keperluan klasifikasi dan mengurangi kompleksitas komputasi.

2. **Penyesuaian Sampling Rate (*Resampling*)**

   Setelah audio diubah menjadi format mono, dilakukan penyesuaian sampling rate (*resampling*). Sampling rate pada dataset UrbanSound8K bervariatif, sehingga sampling rate pada data diubah menjadi 32.000 Hz agar sesuai dengan standar input pada model PANNs.

3.2.4 Augmentasi Temporal (*Random Cropping*)

Seleksi kelas bahaya yang telah dilakukan menghasilkan jumlah data yang relatif sedikit pada kelas yang terpilih, yang berpotensi membuat model kekurangan data untuk latih dan uji. Oleh karena itu, teknik augmentasi hadir sebagai solusi untuk memperkaya variasi data tanpa perlu menambah jumlah sampel dengan dataset lain. Teknik ini juga mempersingkat waktu dan sumber daya komputasi dikarenakan model hanya mempelajari sebagian fitur penting dari seluruh bagian fitur pada data aslinya.

Sebelum melakukan proses augmentasi, durasi audio akan diperiksa terlebih dahulu apakah sesuai dengan standar yang telah ditetapkan, yaitu 5 detik. Durasi 5 detik ini dipilih karena dataset UrbanSound8K memiliki data audio yang berdurasi rata-rata 4 detik, sehingga 5 detik merupakan durasi yang cukup aman untuk dijadikan standar dalam penelitian ini. Jika audio asli berdurasi

kurang dari 5 detik, maka audio akan ditambahkan *padding* hingga durasinya mencapai 5 detik. Jika audio asli berdurasi lebih dari 5 detik, maka audio akan dipotong hingga berdurasi 5 detik. Penetapan standar 5 detik durasi audio merupakan antisipasi terhadap inkonsitensi durasi dan memberikan ruang jelajah yang luas pada algoritma augmentasi. Setelah standarisasi durasi selesai, maka data siap untuk diproses menggunakan teknik augmentasi.

Teknik augmentasi yang diterapkan adalah *Random Cropping*, yaitu pemotongan acak pada segmen audio sepanjang durasi tertentu. Pada setiap *epoch* pelatihan, segmen 1 detik akan diambil secara acak dari durasi 5 detik tersebut. Ini memberikan variasi temporal pada model untuk belajar mengenali karakteristik suara yang berbeda dari berbagai posisi dalam rekaman asli pada setiap *epoch*. Teknik *Random Cropping* ini tidak diterapkan pada data uji dikarenakan berpotensi mengubah distribusi data uji, sehingga model tidak dapat mencapai nilai evaluasi secara maksimal. Strategi ini memastikan bahwa data uji memiliki dimensi yang konsisten, sehingga performa model dapat dievaluasi secara stabil dan tolak ukur pengujian dapat direproduksi dengan akurat.

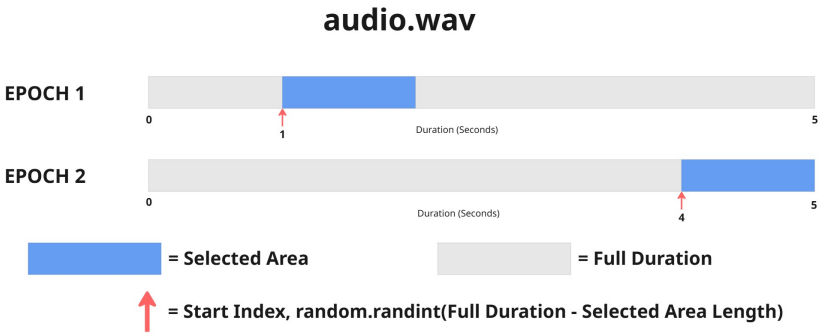

Gambar 3.3 Ilustrasi Teknik *Random Cropping*

3.3 Konfigurasi Model

Model yang digunakan dalam penelitian ini adalah model PANNs [7] dengan 3 arsitektur berbeda, yaitu *Res1dNet31*, *ResNet38*, dan *Wavegram-Logmel-CNN*. Ketiga arsitektur ini telah terbukti memiliki performa yang baik pada tugas klasifikasi audio berdasarkan masing-masing representasi inputnya. Namun, agar model dapat berfungsi optimal sesuai dengan konteks klasifikasi 4 kelas bahaya pada dataset UrbanSound8K, diperlukan beberapa penyesuaian konfigurasi model, yaitu sebagai berikut.

3.3.1 Modifikasi Arsitektur PANNs

Modifikasi beberapa komponen pada arsitektur PANNs diperlukan pada lapisan keluaran (*output layer*). Langkah ini dilakukan mengingat jumlah kelas pada *output layer* yang belum sesuai dengan target kelas suara yang ditentukan dan penyesuaian jenis output klasifikasi PANNs yang awalnya *multi-label*. Oleh karena itu, dilakukan dua penyesuaian utama:

1. **Penyesuaian Jumlah Neuron pada Lapisan Akhir**

   Jumlah *neuron* pada lapisan akhir disesuaikan dari 527 *node* menjadi 4 *node* (sesuai jumlah kelas pilihan).

2. **Penyesuaian Fungsi Aktivasi pada Lapisan Akhir**

   Pada model asli PANNs, lapisan akhir menggunakan fungsi aktivasi *sigmoid* yang mengeluarkan output berupa probabilitas tiap kelasnya sendiri (cocok untuk *multi-label*). Namun, klasifikasi model yang ditentukan pada penelitian ini adalah klasifikasi *Single-Label*, sehingga terjadi modifikasi pada lapisan akhir menjadi lapisan *Linear* yang mengeluarkan angka mentah (*logits*). Nilai *logits* ini nantinya akan dikonversi menjadi distribusi probabilitas tunggal oleh fungsi kerugian (*Loss Function*) selama fase pelatihan. Dengan perubahan ini, model akan memilih satu kelas pemenang dengan probabilitas tertinggi daripada kelas lainnya.

3.3.2 Parameter Konfigurasi Input

Selain melakukan modifikasi arsitektur, konfigurasi parameter input juga disesuaikan dengan standar yang ditetapkan pada PANNs untuk menjamin kompabilitas dimensi fitur antara data input dengan bobot *pre-trained*, sehingga ekstraksi fitur dapat berjalan optimal tanpa adanya kesalahan dimensi. Rincian konfigurasi tersebut meliputi:

Tabel 3.1 Konfigurasi Parameter Input Audio Model PANNs

Parameter	**Nilai**	**Keterangan**
Sampling Rate	32.000 Hz	Frekuensi pencuplikan sinyal audio
Window Size	1024	Ukuran jendela FFT (*Fast Fourier Transform*)
Hop Size	320	Jarak pergeseran antar jendela waktu
Mel-bins	64	Jumlah filter bank pada skala Mel (dimensi fitur vertikal)
F-min	50 Hz	Batas frekuensi minimum
F-max	14.000 Hz	Batas frekuensi maksimum

Penggunaan *sampling rate* 32 kHz dipilih merujuk pada spesifikasi standar PANNs [7]. Angka ini juga telah memenuhi kriteria Teorema Nyquist untuk menangkap frekuensi hingga 16 kHz. Rentang ini dinilai efisien karena sebagian besar energi spektral pada suara bahaya (seperti sirine, klakson, dan tembakan) berada pada rentang 50 Hz hingga 14.000 Hz, sehingga parameter ini dapat mempertahankan informasi vital sekaligus mereduksi beban komputasi dibandingkan standar audio 44.1 kHz.

3.4 Eksperimen *Transfer Learning*

Konsep utama dari *Transfer Learning* adalah memanfaatkan pengetahuan yang telah dipelajari oleh model terlatih sebelumnya (*pre-trained model*) dengan dataset berskala besar untuk diterapkan pada permasalahan spesifik yang memiliki keterbatasan data. Dalam penelitian ini, arsitektur PANNs yang digunakan merupakan *pre-trained model* yang sebelumnya telah dilatih menggunakan dataset AudioSet [7]. AudioSet merupakan sebuah dataset audio

berskala besar yang berisi lebih dari 2.084.320 klip suara berdurasi 10 detik yang mencakup berbagai macam suara manusia, hewan, alat musik, genre dan suara lingkungan dengan 632 kategori kelas (*multi-label classification*) [8]. Adapun data yang digunakan pada saat melatih model PANNs berjumlah 1,9 juta klip suara yang mencakup 527 kategori kelas dari AudioSet [7].

Pada fase *pre-training* tersebut, para peneliti PANNs melatih beberapa varian arsitekturnya menggunakan representasi input yang spesifik, yakni *Raw Waveform*, *Log-mel Spectrogram*, serta kombinasi keduanya (*Hybrid*), untuk mengenali berbagai pola hierarkis suara [7]. Pengetahuan berupa parameter bobot ekstraktor fitur dari masing-masing varian arsitektur inilah yang nantinya akan diadaptasikan ke dalam domain penelitian ini.

Setelah model dikonfigurasi sesuai kebutuhan penelitian, tahap selanjutnya adalah melakukan *fine-tuning model* secara menyeluruh pada dataset UrbanSound8K. Tahapan ini melibatkan konfigurasi hyperparameter pelatihan secara eksperimental dan penerapan beberapa strategi pelatihan yang bertujuan untuk mendapatkan hasil evaluasi yang optimal. Beberapa strategi teknis yang diterapkan mencakup pengondisian lingkungan implementasi, penerapan standar reproduksibilitas, penanganan ketidakseimbangan data, serta mekanisme kontrol pelatihan untuk memastikan model mempelajari data dengan baik dan menghindari *overfitting*. Penggunaan WandB sebagai alat pemantauan dan pencatatan eksperimen pelatihan model secara *real-time* termasuk ke dalam strategi untuk memastikan transparansi dan menjaga validitas dalam merekam hasil eksperimen. Rincian beberapa langkah strategi teknis tersebut dijabarkan sebagai berikut.

3.4.1 Lingkungan Implementasi dan Reproduksibilitas

Seluruh rangkaian eksperimen pelatihan dijalankan pada satu perangkat komputasi terdedikasi guna menjaga konsistensi performa dan waktu komputasi. Mengingat perangkat keras memiliki dampak signifikan terhadap efisiensi

proses *fine-tuning* model, rincian spesifikasi perangkat keras (*hardware*) yang digunakan dijabarkan pada Tabel 3.2.

Tabel 3.2 Spesifikasi Perangkat Keras untuk Pelatihan

Komponen	**Spesifikasi**	**Keterangan**
Processor (CPU)	Intel Core i7-7700HQ	Bertanggung jawab atas *pre-processing* data, augmentasi dan manajemen *dataloader*.
Kartu Grafis (GPU)	NVIDIA GeForce GTX 1050 (4 GB VRAM)	Berperan dalam akselerasi komputasi tensor selama pelatihan model.
Memori (RAM)	8 GB DDR4	Menunjang alokasi data sementara dengan kecepatan transfer 2400 MHz.
Penyimpanan	1 TB HDD	Digunakan sebagai repositori penyimpanan dataset utama.

Selain perangkat keras, lingkungan perangkat lunak juga dikonfigurasi menggunakan pustaka (*library*) standar industri untuk menjamin reliabilitas eksperimen pelatihan. Implementasi dilakukan menggunakan bahasa pemrograman **Python** dengan kerangka kerja utama **PyTorch**. Rincian lengkap *library* yang digunakan beserta fungsinya ditampilkan pada Tabel 3.3.

Tabel 3.3 Daftar Perangkat Lunak dan Pustaka Pendukung

Perangkat Lunak	**Fungsi Utama**
Python	Bahasa pemrograman dasar untuk seluruh implementasi teknis penelitian.
PyTorch	Kerangka kerja utama untuk pembangunan, pelatihan, dan evaluasi model *Deep Learning*.
NumPy	Pustaka komputasi numerik untuk manipulasi matriks dan array.
Scikit-learn	Pustaka untuk perhitungan metrik evaluasi (*F1-Score*) dan *Confusion Matrix*.
Matplotlib & Seaborn	Pustaka visualisasi data untuk pembuatan grafik hasil pelatihan.
Weights & Biases	Platform pemantauan (*monitoring*) metrik pelatihan secara *real-time*.

Guna memastikan eksperimen dapat direproduksi ulang (*reproducible*) pada aspek logika program, dilakukan penguncian benih acak (*Random Seed*) bernilai tetap (42) pada tiga komponen pustaka utama, yaitu:

1. **Python Native Random**

   Mengunci pengacakan pada operasi dasar.

2. **NumPy**

   Menjamin konsistensi pada operasi manipulasi matriks dan pembagian data (*fold splitting*).

3. **PyTorch (CPU & CUDA)**

   Mengunci inisialisasi bobot awal jaringan saraf agar start pelatihan selalu sama.

Meskipun inisialisasi bobot dan pembagian data telah dikunci secara deterministik, konfigurasi `cudnn.deterministic` pada *backend* GPU tetap dinonaktifkan (*False*). Keputusan ini diambil untuk memprioritaskan efisiensi sumber daya dan kecepatan komputasi, mengingat penegakan determinisme penuh pada operasi konvolusi GPU dapat meningkatkan waktu pelatihan secara signifikan. Variasi hasil numerik mikroskopis yang mungkin timbul akibat optimasi perangkat keras ini dinilai dapat diabaikan (*negligible*) dan tidak mempengaruhi validitas tren performa model secara keseluruhan.

3.4.2 Penanganan Ketidakseimbangan Data (*Cost-Sensitive Learning*)

Meskipun dataset UrbanSound8K memiliki distribusi data yang relatif terstruktur, proses seleksi kelas dan penyusunan ulang *fold* berpotensi menghasilkan ketidakseimbangan jumlah sampel antar kelas. Ketidakseimbangan ini dapat memicu bias pada model, di mana model akan cenderung memprediksi kelas mayoritas (jumlah sampel banyak) dan mengabaikan kelas minoritas karena kontribusinya terhadap nilai *loss* yang kecil.

Untuk memitigasi risiko tersebut, diterapkan pendekatan *Cost-Sensitive*

Learning [20] atau pemberian bobot penalti pada fungsi kerugian (*Loss Function*). Strategi ini bekerja dengan memberikan bobot *loss* yang besar pada kelas dengan jumlah sampel sedikit, dan sebaliknya. Hal ini memaksa model untuk memberikan perhatian yang setara pada semua kelas selama proses pembaruan gradien tanpa memperhitungkan jumlah sampelnya.

Bobot penalti (W_j) untuk setiap kelas ke-j dihitung secara otomatis sebelum pelatihan dimulai menggunakan formulasi berikut:

$$W_j = \frac{N}{C \times N_j}$$

(Rumus 3.1)

Keterangan:

- W_j : Bobot skalar yang dihasilkan untuk kelas j.
- N : Total jumlah sampel dalam seluruh dataset latih.
- C : Jumlah kelas total (4 kelas).
- N_j : Jumlah sampel spesifik pada kelas j.

Sebagai ilustrasi, jika kelas *gun_shot* memiliki jumlah sampel yang jauh lebih sedikit dibandingkan *car_horn*, maka nilai N_j yang kecil pada penyebut akan menghasilkan nilai W_j yang besar. Nilai bobot ini kemudian diaplikasikan sebagai argumen parameter pada fungsi *Cross Entropy Loss*. Secara matematis, jika model melakukan kesalahan prediksi pada kelas *gun_shot*, nilai *loss* akan dikalikan dengan faktor W_j yang besar tersebut. Dengan begitu, model akan dihukum lebih berat dan dipaksa untuk belajar mengenali fitur kelas minoritas tersebut.

3.4.3 Konfigurasi *Optimizer* dan *Scheduler*

Proses *fine-tuning* dilakukan secara menyeluruh, baik pada lapisan *backbone* maupun *head* tanpa melakukan pembekuan bobot (*unfrozen layers*). Hal ini bertujuan agar fitur ekstraktor pada model PANNs dapat beradaptasi

sepenuhnya terhadap karakteristik fitur yang diambil dari audio dataset UrbanSound8K, khususnya pada 4 kelas yang telah diseleksi.

Pembaruan bobot model (*weight update*) dilakukan menggunakan algoritma optimasi *optimizer* **AdamW** (*Adam with Weight Decay*). Pemilihan AdamW didasari oleh kemampuannya dalam memisahkan mekanisme pembaruan bobot dengan *weight decay*, sehingga lebih efektif dalam mencegah *overfitting* dibandingkan algoritma Adam standar. Pelatihan dilakukan dalam *batch size* sebesar 8 selama maksimal 50 *epoch*, dengan pengaturan *Learning Rate* awal sebesar 5e-4 dan nilai *Weight Decay* sebesar 1e-4.

Untuk mengoptimalkan proses adaptasi pelatihan model, diterapkan pula penyesuaian laju pembelajaran dinamis menggunakan *scheduler* ***ReduceLROnPlateau***. Mekanisme ini dirancang untuk memantau metrik *Validation Loss*. Apabila nilai kerugian validasi tersebut tidak mengalami penurunan selama 3 *epoch* berturut-turut (*patience*), maka nilai *Learning Rate* akan direduksi secara otomatis sebesar setengah dari nilai sebelumnya (faktor 0,5). Strategi ini membantu model untuk menemukan detail kecil global dengan lebih presisi (konvergensi) saat mendekati akhir pelatihan.

3.4.4 Strategi Optimasi: *Early Stopping* dan *Checkpoint*

Mengingat pelatihan dilakukan pada dataset terbatas, risiko *overfitting* pada *epoch* lanjutan menjadi sangat tinggi. Untuk mencegah hal tersebut, diterapkan dua mekanisme pencegahan otomatis:

1. ***Early Stopping***

   Mekanisme *Early Stopping* berfungsi sebagai penghenti darurat dalam pelatihan model. Hal ini dilakukan untuk mencegah model yang sudah mencapai performa maksimal lebih awal menjadi *overfitting* pada data latih.

   Secara teknis, meskipun batas maksimal jumlah *epoch* telah ditetapkan sebanyak 50 *epoch*, durasi sebenarnya bergantung pada pemantauan

metrik *Validation Loss* sebagai tolak ukur performa model. Ketika metrik tersebut tidak mengalami penurunan melebihi rekor minimal selama 5 *epoch* berturut-turut (*patience*), pelatihan model akan dihentikan secara paksa lebih awal. Mekanisme ini menyebabkan model tidak diberikan kesempatan untuk terus belajar data yang nantinya akan dihafal oleh model tersebut.

2. ***Model Checkpointing***

   Mekanisme *checkpointing* berfungsi untuk menyimpan parameter bobot model terbaik secara otomatis. Selama proses pelatihan berjalan, sistem secara dinamis hanya akan menyimpan file bobot pada *epoch* yang berhasil mencetak nilai *F1-Score* validasi tertinggi. Jika performa pada *epoch* selanjutnya memburuk, parameter bobot model tidak akan diperbarui, sehingga hasil akhir yang dievaluasi dipastikan adalah versi model dengan konfigurasi bobot paling optimal.

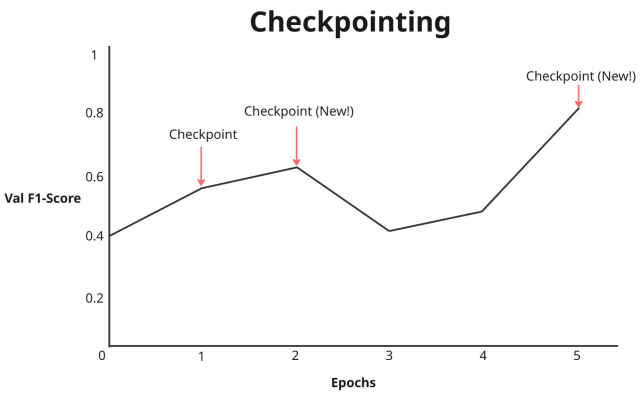

Gambar 3.4 Ilustrasi Mekanisme *Checkpointing*

Contoh mekanisme ini dapat dilihat pada Gambar 3.4. Pada *epoch* ke-1 dan ke-2, model mencetak nilai *validation F1-Score* yang terus meningkat, sehingga *checkpointing* dilakukan 2 kali berturut-turut (memperbarui

rekor lama). Namun pada *epoch* ke-3, nilai tersebut menurun cukup drastis, sehingga sistem tetap mempertahankan bobot dari *epoch* ke-2. Walaupun terdapat kenaikan nilai pada *epoch* ke-4, capaiannya belum melampaui rekor *epoch* ke-2, sehingga tidak terjadi *checkpointing* baru. Pembaruan *checkpoint* akhirnya dilakukan kembali pada *epoch* ke-5 karena nilainya berhasil mengalahkan rekor *epoch* ke-2. Dengan demikian, parameter bobot dari *epoch* ke-5 inilah yang disimpan sebagai model final untuk tahap pengujian.

3.4.5 Pemantauan dan Pencatatan Eksperimen

Dalam memantau pergerakan metrik evaluasi pelatihan (termasuk *Train/Validation Loss*, *F1-Score*, dan pergerakan *Learning Rate*), metrik tersebut direkam dan divisualisasikan secara *real-time* menggunakan alat bantu berupa *dashboard* **Weights & Biases (WandB)**. Penggunaan alat ini memastikan transparansi rekam jejak pelatihan model. Di akhir setiap pengujian *fold*, sistem juga secara otomatis menggenerasi laporan grafik riwayat pelatihan dengan menampilkan metrik yang dijadikan bahan evaluasi.

3.4.6 Konfigurasi Parameter Pelatihan

Rincian skenario pelatihan tadi telah membawa beberapa hyperparameter yang akan dijadikan sebagai tolak ukur eksperimen pada training model. Hyperparameter yang dikendalikan dalam eksperimen ini disajikan pada Tabel 3.4. Nilai-nilai yang ditetapkan dalam tabel ini ditetapkan berdasarkan studi literatur dan eksperimen awal untuk mendapatkan konvergensi yang optimal.

Tabel 3.4 Parameter Konfigurasi Pelatihan

Kategori	**Konfigurasi / Nilai**
Hyperparameter Training	
Batch Size	8
Epoch	50
Num Workers	2
Learning Rate Awal	0.0005 ($5e^{-4}$)
Optimizer	
Tipe	AdamW
Weight Decay	0.0001 ($1e^{-4}$)
Learning Rate Scheduler	
Tipe	ReduceLROnPlateau
Faktor Pengurangan	0.5
Patience	3
Target Metrik	Validation Loss
Early Stopping	
Patience	5
Target Metrik	Validation F1-Score <= Best Validation F1-Score

3.5 Analisis dan Evaluasi

Setelah proses pelatihan selesai, kinerja model diukur menggunakan empat indikator utama:

1. ***F1-Score***

   Digunakan sebagai metrik utama untuk mengukur akurasi dan sensitivitas model secara harmonis, memastikan semua kelas bahaya terdeteksi dengan baik.

2. **Nilai *Loss***

   Digunakan untuk memantau proses konvergensi model selama pelatihan dan mendeteksi indikasi *overfitting* atau *underfitting*.

3. ***Confusion Matrix***

Digunakan untuk melihat detail distribusi prediksi benar dan salah pada setiap kelas spesifik.

DAFTAR PUSTAKA

[1] World Health Organization. *Global Status Report on Road Safety 2023*. Geneva: World Health Organization, 2023. ISBN: 9789240086517.

[2] Birgitta Thorslund et al. "Effects of hearing loss on traffic safety and mobility". *European Transport Research Review* 5 (2013), pp. 113–121.

[3] Brian C. J. Moore. "Perceptual Consequences of Cochlear Hearing Loss and their Implications for the Design of Hearing Aids". *Ear and Hearing* 17.2 (1996), pp. 133–161.

[4] Michael Büchler et al. "Sound classification in hearing aids inspired by auditory scene analysis". *The Journal of the Acoustical Society of America* 118.3 (2005), pp. 2057–2057.

[5] Justin Salamon, Christopher Jacoby, and Juan Pablo Bello. "A Dataset and Taxonomy for Urban Sound Research". *Proceedings of the 22nd ACM International Conference on Multimedia*. ACM. 2014, pp. 1041–1044.

[6] Karol J Piczak. "Environmental sound classification with convolutional neural networks". *2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP)*. IEEE. 2015, pp. 1–6.

[7] Qiuqiang Kong et al. "PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition". *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 28 (2020), pp. 2880–2894.

[8] Jort F Gemmeke et al. "Audio set: An ontology and human-labeled dataset for audio events". *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE. 2017, pp. 776–780.

[9] Anam Bansal and Naresh Kumar Garg. “Environmental Sound Classification: A descriptive review of the literature”. *Intelligent Systems with Applications* 16 (2022), p. 200115.

[10] Sebastien Tremblay et al. “Exploiting Environmental Sounds for Activity Recognition in Smart Homes”. *Artificial Intelligence Applied to Assistive Technologies and Smart Environments* (2015).

[11] Dongping Zhang et al. “An Automatic Classification System for Environmental Sound in Smart Cities”. *Sensors* 23.15 (2023), p. 6823.

[12] Alan V Oppenheim and Ronald W Schafer. *Discrete-Time Signal Processing*. 3rd. Upper Saddle River, NJ: Pearson, 2010.

[13] Ze-Nian Li, Mark S Drew, and Jiangchuan Liu. *Fundamentals of Multimedia*. 2nd. Cham: Springer, 2014.

[14] David A Patterson and John L Hennessy. *Computer Organization and Design: The Hardware/Software Interface*. 5th. Waltham, MA: Morgan Kaufmann, 2013.

[15] Jiawei Han, Jian Pei, and Micheline Kamber. *Data mining: concepts and techniques*. Elsevier, 2011.

[16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep learning*. MIT press, 2016.

[17] John G Proakis and Dimitris G Manolakis. *Digital signal processing: principles, algorithms, and applications*. Pearson Prentice Hall, 2006.

[18] Tuomas Virtanen, Mark D Plumbley, and Dan Ellis. *Computational analysis of sound scenes and events*. Springer, 2018.

[19] Meinard Müller. *Fundamentals of music processing: Audio, analysis, algorithms, applications*. Springer, 2015.

[20] Charles Elkan. “The Foundations of Cost-Sensitive Learning”. *Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI)*. Vol. 17. 1. Seattle, WA, USA: Morgan Kaufmann Publishers Inc., 2001, pp. 973–978.